

Cloris AI RAG 批量 Embedding 压测长文

本文档用于切块与批量 embedding 对照实验。默认 maxChars=500、overlap=100 时应产生数十到上百个 chunk。

入库示例（先启动 next dev）：

```
pnpm seed:docs -- apps/ai-chatbot/app/docs/RAG 批量 Embedding 压测长文.md
```

1. RAG 总览（员工手册与请假出差报销）

检索增强生成把知识库与大语言模型解耦。系统先检索相关片段，再把片段作为上下文交给模型生成回答，便于更新知识、追溯出处，也降低幻觉。在「员工手册与请假出差报销」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 1 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：员工手册与请假出差报销、RAG、Embedding、LanceDB、切块、召回、TopK。

2. 切块策略（开发规范 React TypeScript Next.js）

RecursiveCharacterTextSplitter 从粗到细尝试分隔符：空行、换行、中英文句读、逗号、空格，最后才按字符硬切。默认 maxChars=500、overlap=100，兼顾召回粒度与上下文连贯。在「开发规范 React TypeScript Next.js」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 2 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：开发规范 React TypeScript Next.js、RAG、Embedding、LanceDB、切块、召回、TopK。

3. Embedding（Prisma 与 PostgreSQL 建模）

本项目使用 Xenova/all-MiniLM-L6-v2 量化 ONNX 模型，在 Node 本地推理，输出 384 维 L2 归一化向量。写入 LanceDB 时由 Embedding Function 自动生成 vector。在「Prisma 与 PostgreSQL 建模」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 3 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持

可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：Prisma 与 PostgreSQL 建模、RAG、Embedding、LanceDB、切块、召回、TopK。

4. 批量推理（鉴权 Token 与 apiFetch）

computeSourceEmbeddings 按 batchSize 切片，一次前向处理多句。n 很小时批量未必更快；n 较大（数十到上百 chunk）时减少前向次数更有收益。注意 padding 与 CPU 小 batch 开销。在「鉴权 Token 与 apiFetch」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 4 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：鉴权 Token 与 apiFetch、RAG、Embedding、LanceDB、切块、召回、TopK。

5. LanceDB（会话 Session 与 Message 持久化）

向量行包含 id、documentId、title、filename、page、snippet、index 与 vector。表带 embedding_functions 元数据，search(文本) 会自动 embed query。在「会话 Session 与 Message 持久化」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 5 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：会话 Session 与 Message 持久化、RAG、Embedding、LanceDB、切块、召回、TopK。

6. PostgreSQL（知识库 CRUD 与回收站）

Document 存在 Postgres，经 Prisma 管理。软删除用 deletedAt；恢复后需重新 indexDocumentChunks 写回向量。文件名 filename 与 chunk 元数据对齐。在「知识库 CRUD 与回收站」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 6 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：知识库 CRUD 与回收站、RAG、

Embedding、LanceDB、切块、召回、TopK。

7. PDF 入库（检索页冷热对比实验）

pdf-parse 抽文本与分页，清洗页脚与软换行后 createDocument。若传 pages，则按页切块并写入真实 page；否则全文切块 page=0。在「检索页冷热对比实验」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 7 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：检索页冷热对比实验、RAG、Embedding、LanceDB、切块、召回、TopK。

8. 检索 API（bench-retrieval 固定参数）

POST /api/retrieval 接收 query、k、可选 docId。searchSnippets 返回 hits 与 timings：openTableMs、searchMs、mapMs，路由再补 validateMs 与 totalMs。在「bench-retrieval 固定参数」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 8 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：bench-retrieval 固定参数、RAG、Embedding、LanceDB、切块、召回、TopK。

9. 耗时解读（HF 镜像与模型缓存）

冷启动首请求常含模型加载；热路径看 searchMs。入库优化看 embedMs 与 POST /api/documents 墙钟，不要用检索耗时衡量批量 embed。在「HF 镜像与模型缓存」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 9 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：HF 镜像与模型缓存、RAG、Embedding、LanceDB、切块、召回、TopK。

10. 质量回归（Windows 上 ONNX 注意事项）

对照 batchSize=1 与 16 的向量余弦应接近 1；同 query 的 top-k 文档 id 排序应大致稳

定。切块切断关键句时召回会抖，需检查分隔符与 `overlap`。在「Windows 上 ONNX 注意事项」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 10 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、`embedding` 与 `ANN` 检索四段耗时。工程上优先保证正确性与可观测性，再谈 `batchSize` 与并发。本段用于拉长文本以便 `RecursiveCharacterTextSplitter` 产生更多 `chunk`，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 `schema`、观察 `[embed:write]` 日志中的 `n/batches/ms`，并与 `batchSize=1` 基线对比。相关关键词：Windows 上 ONNX 注意事项、RAG、Embedding、LanceDB、切块、召回、TopK。

11. RAG 总览（Chunk 元数据 filename 与 page）

检索增强生成把知识库与大语言模型解耦。系统先检索相关片段，再把片段作为上下文交给模型生成回答，便于更新知识、追溯出处，也降低幻觉。在「Chunk 元数据 filename 与 page」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 11 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、`embedding` 与 `ANN` 检索四段耗时。工程上优先保证正确性与可观测性，再谈 `batchSize` 与并发。本段用于拉长文本以便 `RecursiveCharacterTextSplitter` 产生更多 `chunk`，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 `schema`、观察 `[embed:write]` 日志中的 `n/batches/ms`，并与 `batchSize=1` 基线对比。相关关键词：Chunk 元数据 filename 与 page、RAG、Embedding、LanceDB、切块、召回、TopK。

12. 切块策略（软删除后向量清理）

`RecursiveCharacterTextSplitter` 从粗到细尝试分隔符：空行、换行、中英文句读、逗号、空格，最后才按字符硬切。默认 `maxChars=500`、`overlap=100`，兼顾召回粒度与上下文连贯。在「软删除后向量清理」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 12 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、`embedding` 与 `ANN` 检索四段耗时。工程上优先保证正确性与可观测性，再谈 `batchSize` 与并发。本段用于拉长文本以便 `RecursiveCharacterTextSplitter` 产生更多 `chunk`，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 `schema`、观察 `[embed:write]` 日志中的 `n/batches/ms`，并与 `batchSize=1` 基线对比。相关关键词：软删除后向量清理、RAG、Embedding、LanceDB、切块、召回、TopK。

13. Embedding（恢复文档后重建索引）

本项目使用 `Xenova/all-MiniLM-L6-v2` 量化 ONNX 模型，在 Node 本地推理，输出 384 维 L2 归一化向量。写入 LanceDB 时由 `Embedding Function` 自动生成 `vector`。在「恢复文档后重建索引」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 13 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、`embedding` 与 `ANN` 检索四段耗时。工程上优先保证正确性与可观测性，再谈 `batchSize` 与并发。本段用于拉长文本以便 `RecursiveCharacterTextSplitter` 产生更多 `chunk`，内容仍保持

可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：恢复文档后重建索引、RAG、Embedding、LanceDB、切块、召回、TopK。

14. 批量推理（TopK 与相似度阈值）

computeSourceEmbeddings 按 batchSize 切片，一次前向处理多句。n 很小时批量未必更快；n 较大（数十到上百 chunk）时减少前向次数更有收益。注意 padding 与 CPU 小 batch 开销。在「TopK 与相似度阈值」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 14 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：TopK 与相似度阈值、RAG、Embedding、LanceDB、切块、召回、TopK。

15. LanceDB（中文分隔符与英文句号冲突）

向量行包含 id、documentId、title、filename、page、snippet、index 与 vector。表带 embedding_functions 元数据，search(文本) 会自动 embed query。在「中文分隔符与英文句号冲突」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 15 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：中文分隔符与英文句号冲突、RAG、Embedding、LanceDB、切块、召回、TopK。

16. PostgreSQL（overlap 过大导致冗余）

Document 存在 Postgres，经 Prisma 管理。软删除用 deletedAt；恢复后需重新 indexDocumentChunks 写回向量。文件名 filename 与 chunk 元数据对齐。在「overlap 过大导致冗余」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 16 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：overlap 过大导致冗余、RAG、

Embedding、LanceDB、切块、召回、TopK。

17. PDF 入库（maxChars 过小导致碎片）

pdf-parse 抽文本与分页，清洗页脚与软换行后 createDocument。若传 pages，则按页切块并写入真实 page；否则全文切块 page=0。在「maxChars 过小导致碎片」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 17 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：maxChars 过小导致碎片、RAG、Embedding、LanceDB、切块、召回、TopK。

18. 检索 API（批量大小 8/16/32 扫参）

POST /api/retrieval 接收 query、k、可选 docId。searchSnippets 返回 hits 与 timings：openTableMs、searchMs、mapMs，路由再补 validateMs 与 totalMs。在「批量大小 8/16/32 扫参」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 18 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：批量大小 8/16/32 扫参、RAG、Embedding、LanceDB、切块、召回、TopK。

19. 耗时解读（padding 最长句成本）

冷启动首请求常含模型加载；热路径看 searchMs。入库优化看 embedMs 与 POST /api/documents 墙钟，不要用检索耗时衡量批量 embed。在「padding 最长句成本」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 19 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：padding 最长句成本、RAG、Embedding、LanceDB、切块、召回、TopK。

20. 质量回归（warmup 后再测平均值）

对照 batchSize=1 与 16 的向量余弦应接近 1；同 query 的 top-k 文档 id 排序应大致稳定。切块切断关键句时召回会抖，需检查分隔符与 overlap。在「warmup 后再测平均值」

场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 20 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：warmup 后再测平均值、RAG、Embedding、LanceDB、切块、召回、TopK。

21. RAG 总览（员工手册与请假出差报销）

检索增强生成把知识库与大语言模型解耦。系统先检索相关片段，再把片段作为上下文交给模型生成回答，便于更新知识、追溯出处，也降低幻觉。在「员工手册与请假出差报销」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 21 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：员工手册与请假出差报销、RAG、Embedding、LanceDB、切块、召回、TopK。

22. 切块策略（开发规范 React TypeScript Next.js）

RecursiveCharacterTextSplitter 从粗到细尝试分隔符：空行、换行、中英文句读、逗号、空格，最后才按字符硬切。默认 maxChars=500、overlap=100，兼顾召回粒度与上下文连贯。在「开发规范 React TypeScript Next.js」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 22 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：开发规范 React TypeScript Next.js、RAG、Embedding、LanceDB、切块、召回、TopK。

23. Embedding（Prisma 与 PostgreSQL 建模）

本项目使用 Xenova/all-MiniLM-L6-v2 量化 ONNX 模型，在 Node 本地推理，输出 384 维 L2 归一化向量。写入 LanceDB 时由 Embedding Function 自动生成 vector。在「Prisma 与 PostgreSQL 建模」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 23 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：Prisma 与 PostgreSQL 建模、RAG、Embedding、LanceDB、切块、召回、TopK。

24. 批量推理（鉴权 Token 与 apiFetch）

computeSourceEmbeddings 按 batchSize 切片，一次前向处理多句。n 很小时批量未必更快；n 较大（数十到上百 chunk）时减少前向次数更有收益。注意 padding 与 CPU 小 batch 开销。在「鉴权 Token 与 apiFetch」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 24 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：鉴权 Token 与 apiFetch、RAG、Embedding、LanceDB、切块、召回、TopK。

25. LanceDB（会话 Session 与 Message 持久化）

向量行包含 id、documentId、title、filename、page、snippet、index 与 vector。表带 embedding_functions 元数据，search(文本) 会自动 embed query。在「会话 Session 与 Message 持久化」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 25 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：会话 Session 与 Message 持久化、RAG、Embedding、LanceDB、切块、召回、TopK。

26. PostgreSQL（知识库 CRUD 与回收站）

Document 存在 Postgres，经 Prisma 管理。软删除用 deletedAt；恢复后需重新 indexDocumentChunks 写回向量。文件名 filename 与 chunk 元数据对齐。在「知识库 CRUD 与回收站」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 26 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：知识库 CRUD 与回收站、RAG、Embedding、LanceDB、切块、召回、TopK。

27. PDF 入库（检索页冷热对比实验）

pdf-parse 抽文本与分页，清洗页脚与软换行后 createDocument。若传 pages，则按页切块并写入真实 page；否则全文切块 page=0。在「检索页冷热对比实验」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 27 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：检索页冷热对比实验、RAG、Embedding、LanceDB、切块、召回、TopK。

28. 检索 API（bench-retrieval 固定参数）

POST /api/retrieval 接收 query、k、可选 docId。searchSnippets 返回 hits 与 timings：openTableMs、searchMs、mapMs，路由再补 validateMs 与 totalMs。在「bench-retrieval 固定参数」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 28 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：bench-retrieval 固定参数、RAG、Embedding、LanceDB、切块、召回、TopK。

29. 耗时解读（HF 镜像与模型缓存）

冷启动首请求常含模型加载；热路径看 searchMs。入库优化看 embedMs 与 POST /api/documents 墙钟，不要用检索耗时衡量批量 embed。在「HF 镜像与模型缓存」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 29 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：HF 镜像与模型缓存、RAG、Embedding、LanceDB、切块、召回、TopK。

30. 质量回归（Windows 上 ONNX 注意事项）

对照 batchSize=1 与 16 的向量余弦应接近 1；同 query 的 top-k 文档 id 排序应大致稳定。切块切断关键句时召回会抖，需检查分隔符与 overlap。在「Windows 上 ONNX 注意

事项」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 30 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：Windows 上 ONNX 注意事项、RAG、Embedding、LanceDB、切块、召回、TopK。

31. RAG 总览（Chunk 元数据 filename 与 page）

检索增强生成把知识库与大语言模型解耦。系统先检索相关片段，再把片段作为上下文交给模型生成回答，便于更新知识、追溯出处，也降低幻觉。在「Chunk 元数据 filename 与 page」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 31 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：Chunk 元数据 filename 与 page、RAG、Embedding、LanceDB、切块、召回、TopK。

32. 切块策略（软删除后向量清理）

RecursiveCharacterTextSplitter 从粗到细尝试分隔符：空行、换行、中英文句读、逗号、空格，最后才按字符硬切。默认 maxChars=500、overlap=100，兼顾召回粒度与上下文连贯。在「软删除后向量清理」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 32 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：软删除后向量清理、RAG、Embedding、LanceDB、切块、召回、TopK。

33. Embedding（恢复文档后重建索引）

本项目使用 Xenova/all-MiniLM-L6-v2 量化 ONNX 模型，在 Node 本地推理，输出 384 维 L2 归一化向量。写入 LanceDB 时由 Embedding Function 自动生成 vector。在「恢复文档后重建索引」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 33 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：恢复文档后重建索引、RAG、Embedding、LanceDB、切块、召回、TopK。

34. 批量推理（TopK 与相似度阈值）

computeSourceEmbeddings 按 batchSize 切片，一次前向处理多句。n 很小时批量未必更快；n 较大（数十到上百 chunk）时减少前向次数更有收益。注意 padding 与 CPU 小 batch 开销。在「TopK 与相似度阈值」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 34 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：TopK 与相似度阈值、RAG、Embedding、LanceDB、切块、召回、TopK。

35. LanceDB（中文分隔符与英文句号冲突）

向量行包含 id、documentId、title、filename、page、snippet、index 与 vector。表带 embedding_functions 元数据，search(文本) 会自动 embed query。在「中文分隔符与英文句号冲突」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 35 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：中文分隔符与英文句号冲突、RAG、Embedding、LanceDB、切块、召回、TopK。

36. PostgreSQL（overlap 过大导致冗余）

Document 存在 Postgres，经 Prisma 管理。软删除用 deletedAt；恢复后需重新 indexDocumentChunks 写回向量。文件名 filename 与 chunk 元数据对齐。在「overlap 过大导致冗余」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 36 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：overlap 过大导致冗余、RAG、Embedding、LanceDB、切块、召回、TopK。

37. PDF 入库 (maxChars 过小导致碎片)

pdf-parse 抽文本与分页, 清洗页脚与软换行后 createDocument。若传 pages, 则按页切块并写入真实 page; 否则全文切块 page=0。在「maxChars 过小导致碎片」场景下, 建议把输入规模、硬件与实测延迟记进实验笔记。第 37 段强调: 召回片段应可追溯到文件名与页码, 回答中给出依据。若延迟异常, 先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性, 再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk, 内容仍保持可读。

实践清单: 检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms, 并与 batchSize=1 基线对比。相关关键词: maxChars 过小导致碎片、RAG、Embedding、LanceDB、切块、召回、TopK。

38. 检索 API (批量大小 8/16/32 扫参)

POST /api/retrieval 接收 query、k、可选 docId。searchSnippets 返回 hits 与 timings: openTableMs、searchMs、mapMs, 路由再补 validateMs 与 totalMs。在「批量大小 8/16/32 扫参」场景下, 建议把输入规模、硬件与实测延迟记进实验笔记。第 38 段强调: 召回片段应可追溯到文件名与页码, 回答中给出依据。若延迟异常, 先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性, 再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk, 内容仍保持可读。

实践清单: 检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms, 并与 batchSize=1 基线对比。相关关键词: 批量大小 8/16/32 扫参、RAG、Embedding、LanceDB、切块、召回、TopK。

39. 耗时解读 (padding 最长句成本)

冷启动首请求常含模型加载; 热路径看 searchMs。入库优化看 embedMs 与 POST /api/documents 墙钟, 不要用检索耗时衡量批量 embed。在「padding 最长句成本」场景下, 建议把输入规模、硬件与实测延迟记进实验笔记。第 39 段强调: 召回片段应可追溯到文件名与页码, 回答中给出依据。若延迟异常, 先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性, 再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk, 内容仍保持可读。

实践清单: 检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms, 并与 batchSize=1 基线对比。相关关键词: padding 最长句成本、RAG、Embedding、LanceDB、切块、召回、TopK。

40. 质量回归 (warmup 后再测平均值)

对照 batchSize=1 与 16 的向量余弦应接近 1; 同 query 的 top-k 文档 id 排序应大致稳定。切块切断关键句时召回会抖, 需检查分隔符与 overlap。在「warmup 后再测平均值」场景下, 建议把输入规模、硬件与实测延迟记进实验笔记。第 40 段强调: 召回片段应可追

溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：warmup 后再测平均值、RAG、Embedding、LanceDB、切块、召回、TopK。

41. RAG 总览（员工手册与请假出差报销）

检索增强生成把知识库与大语言模型解耦。系统先检索相关片段，再把片段作为上下文交给模型生成回答，便于更新知识、追溯出处，也降低幻觉。在「员工手册与请假出差报销」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 41 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：员工手册与请假出差报销、RAG、Embedding、LanceDB、切块、召回、TopK。

42. 切块策略（开发规范 React TypeScript Next.js）

RecursiveCharacterTextSplitter 从粗到细尝试分隔符：空行、换行、中英文句读、逗号、空格，最后才按字符硬切。默认 maxChars=500、overlap=100，兼顾召回粒度与上下文连贯。在「开发规范 React TypeScript Next.js」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 42 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：开发规范 React TypeScript Next.js、RAG、Embedding、LanceDB、切块、召回、TopK。

43. Embedding（Prisma 与 PostgreSQL 建模）

本项目使用 Xenova/all-MiniLM-L6-v2 量化 ONNX 模型，在 Node 本地推理，输出 384 维 L2 归一化向量。写入 LanceDB 时由 Embedding Function 自动生成 vector。在「Prisma 与 PostgreSQL 建模」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 43 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的

n/batches/ms, 并与 batchSize=1 基线对比。相关关键词: Prisma 与 PostgreSQL 建模、RAG、Embedding、LanceDB、切块、召回、TopK。

44. 批量推理（鉴权 Token 与 apiFetch）

computeSourceEmbeddings 按 batchSize 切片, 一次前向处理多句。n 很小时批量未必更快; n 较大(数十到上百 chunk)时减少前向次数更有收益。注意 padding 与 CPU 小 batch 开销。在「鉴权 Token 与 apiFetch」场景下, 建议把输入规模、硬件与实测延迟记进实验笔记。第 44 段强调: 召回片段应可追溯到文件名与页码, 回答中给出依据。若延迟异常, 先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性, 再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk, 内容仍保持可读。

实践清单: 检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms, 并与 batchSize=1 基线对比。相关关键词: 鉴权 Token 与 apiFetch、RAG、Embedding、LanceDB、切块、召回、TopK。

45. LanceDB（会话 Session 与 Message 持久化）

向量行包含 id、documentId、title、filename、page、snippet、index 与 vector。表带 embedding_functions 元数据, search(文本) 会自动 embed query。在「会话 Session 与 Message 持久化」场景下, 建议把输入规模、硬件与实测延迟记进实验笔记。第 45 段强调: 召回片段应可追溯到文件名与页码, 回答中给出依据。若延迟异常, 先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性, 再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk, 内容仍保持可读。

实践清单: 检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms, 并与 batchSize=1 基线对比。相关关键词: 会话 Session 与 Message 持久化、RAG、Embedding、LanceDB、切块、召回、TopK。

46. PostgreSQL（知识库 CRUD 与回收站）

Document 存在 Postgres, 经 Prisma 管理。软删除用 deletedAt; 恢复后需重新 indexDocumentChunks 写回向量。文件名 filename 与 chunk 元数据对齐。在「知识库 CRUD 与回收站」场景下, 建议把输入规模、硬件与实测延迟记进实验笔记。第 46 段强调: 召回片段应可追溯到文件名与页码, 回答中给出依据。若延迟异常, 先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性, 再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk, 内容仍保持可读。

实践清单: 检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms, 并与 batchSize=1 基线对比。相关关键词: 知识库 CRUD 与回收站、RAG、Embedding、LanceDB、切块、召回、TopK。

47. PDF 入库（检索页冷热对比实验）

pdf-parse 抽文本与分页，清洗页脚与软换行后 createDocument。若传 pages，则按页切块并写入真实 page；否则全文切块 page=0。在「检索页冷热对比实验」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 47 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：检索页冷热对比实验、RAG、Embedding、LanceDB、切块、召回、TopK。

48. 检索 API（bench-retrieval 固定参数）

POST /api/retrieval 接收 query、k、可选 docId。searchSnippets 返回 hits 与 timings：openTableMs、searchMs、mapMs，路由再补 validateMs 与 totalMs。在「bench-retrieval 固定参数」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 48 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：bench-retrieval 固定参数、RAG、Embedding、LanceDB、切块、召回、TopK。

49. 耗时解读（HF 镜像与模型缓存）

冷启动首请求常含模型加载；热路径看 searchMs。入库优化看 embedMs 与 POST /api/documents 墙钟，不要用检索耗时衡量批量 embed。在「HF 镜像与模型缓存」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 49 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：HF 镜像与模型缓存、RAG、Embedding、LanceDB、切块、召回、TopK。

50. 质量回归（Windows 上 ONNX 注意事项）

对照 batchSize=1 与 16 的向量余弦应接近 1；同 query 的 top-k 文档 id 排序应大致稳定。切块切断关键句时召回会抖，需检查分隔符与 overlap。在「Windows 上 ONNX 注意

事项」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 50 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：Windows 上 ONNX 注意事项、RAG、Embedding、LanceDB、切块、召回、TopK。

51. RAG 总览（Chunk 元数据 filename 与 page）

检索增强生成把知识库与大语言模型解耦。系统先检索相关片段，再把片段作为上下文交给模型生成回答，便于更新知识、追溯出处，也降低幻觉。在「Chunk 元数据 filename 与 page」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 51 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：Chunk 元数据 filename 与 page、RAG、Embedding、LanceDB、切块、召回、TopK。

52. 切块策略（软删除后向量清理）

RecursiveCharacterTextSplitter 从粗到细尝试分隔符：空行、换行、中英文句读、逗号、空格，最后才按字符硬切。默认 maxChars=500、overlap=100，兼顾召回粒度与上下文连贯。在「软删除后向量清理」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 52 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：软删除后向量清理、RAG、Embedding、LanceDB、切块、召回、TopK。

53. Embedding（恢复文档后重建索引）

本项目使用 Xenova/all-MiniLM-L6-v2 量化 ONNX 模型，在 Node 本地推理，输出 384 维 L2 归一化向量。写入 LanceDB 时由 Embedding Function 自动生成 vector。在「恢复文档后重建索引」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 53 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：恢复文档后重建索引、RAG、Embedding、LanceDB、切块、召回、TopK。

54. 批量推理（TopK 与相似度阈值）

computeSourceEmbeddings 按 batchSize 切片，一次前向处理多句。n 很小时批量未必更快；n 较大（数十到上百 chunk）时减少前向次数更有收益。注意 padding 与 CPU 小 batch 开销。在「TopK 与相似度阈值」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 54 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：TopK 与相似度阈值、RAG、Embedding、LanceDB、切块、召回、TopK。

55. LanceDB（中文分隔符与英文句号冲突）

向量行包含 id、documentId、title、filename、page、snippet、index 与 vector。表带 embedding_functions 元数据，search(文本) 会自动 embed query。在「中文分隔符与英文句号冲突」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 55 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：中文分隔符与英文句号冲突、RAG、Embedding、LanceDB、切块、召回、TopK。

56. PostgreSQL（overlap 过大导致冗余）

Document 存在 Postgres，经 Prisma 管理。软删除用 deletedAt；恢复后需重新 indexDocumentChunks 写回向量。文件名 filename 与 chunk 元数据对齐。在「overlap 过大导致冗余」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 56 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：overlap 过大导致冗余、RAG、Embedding、LanceDB、切块、召回、TopK。

57. PDF 入库（maxChars 过小导致碎片）

pdf-parse 抽文本与分页，清洗页脚与软换行后 createDocument。若传 pages，则按页切块并写入真实 page；否则全文切块 page=0。在「maxChars 过小导致碎片」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 57 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：maxChars 过小导致碎片、RAG、Embedding、LanceDB、切块、召回、TopK。

58. 检索 API（批量大小 8/16/32 扫参）

POST /api/retrieval 接收 query、k、可选 docId。searchSnippets 返回 hits 与 timings：openTableMs、searchMs、mapMs，路由再补 validateMs 与 totalMs。在「批量大小 8/16/32 扫参」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 58 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：批量大小 8/16/32 扫参、RAG、Embedding、LanceDB、切块、召回、TopK。

59. 耗时解读（padding 最长句成本）

冷启动首请求常含模型加载；热路径看 searchMs。入库优化看 embedMs 与 POST /api/documents 墙钟，不要用检索耗时衡量批量 embed。在「padding 最长句成本」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 59 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：padding 最长句成本、RAG、Embedding、LanceDB、切块、召回、TopK。

60. 质量回归（warmup 后再测平均值）

对照 batchSize=1 与 16 的向量余弦应接近 1；同 query 的 top-k 文档 id 排序应大致稳定。切块切断关键句时召回会抖，需检查分隔符与 overlap。在「warmup 后再测平均值」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 60 段强调：召回片段应可追

溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：warmup 后再测平均值、RAG、Embedding、LanceDB、切块、召回、TopK。

61. RAG 总览（员工手册与请假出差报销）

检索增强生成把知识库与大语言模型解耦。系统先检索相关片段，再把片段作为上下文交给模型生成回答，便于更新知识、追溯出处，也降低幻觉。在「员工手册与请假出差报销」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 61 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：员工手册与请假出差报销、RAG、Embedding、LanceDB、切块、召回、TopK。

62. 切块策略（开发规范 React TypeScript Next.js）

RecursiveCharacterTextSplitter 从粗到细尝试分隔符：空行、换行、中英文句读、逗号、空格，最后才按字符硬切。默认 maxChars=500、overlap=100，兼顾召回粒度与上下文连贯。在「开发规范 React TypeScript Next.js」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 62 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：开发规范 React TypeScript Next.js、RAG、Embedding、LanceDB、切块、召回、TopK。

63. Embedding（Prisma 与 PostgreSQL 建模）

本项目使用 Xenova/all-MiniLM-L6-v2 量化 ONNX 模型，在 Node 本地推理，输出 384 维 L2 归一化向量。写入 LanceDB 时由 Embedding Function 自动生成 vector。在「Prisma 与 PostgreSQL 建模」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 63 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的

n/batches/ms, 并与 batchSize=1 基线对比。相关关键词: Prisma 与 PostgreSQL 建模、RAG、Embedding、LanceDB、切块、召回、TopK。

64. 批量推理（鉴权 Token 与 apiFetch）

computeSourceEmbeddings 按 batchSize 切片, 一次前向处理多句。n 很小时批量未必更快; n 较大(数十到上百 chunk)时减少前向次数更有收益。注意 padding 与 CPU 小 batch 开销。在「鉴权 Token 与 apiFetch」场景下, 建议把输入规模、硬件与实测延迟记进实验笔记。第 64 段强调: 召回片段应可追溯到文件名与页码, 回答中给出依据。若延迟异常, 先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性, 再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk, 内容仍保持可读。

实践清单: 检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms, 并与 batchSize=1 基线对比。相关关键词: 鉴权 Token 与 apiFetch、RAG、Embedding、LanceDB、切块、召回、TopK。

65. LanceDB（会话 Session 与 Message 持久化）

向量行包含 id、documentId、title、filename、page、snippet、index 与 vector。表带 embedding_functions 元数据, search(文本) 会自动 embed query。在「会话 Session 与 Message 持久化」场景下, 建议把输入规模、硬件与实测延迟记进实验笔记。第 65 段强调: 召回片段应可追溯到文件名与页码, 回答中给出依据。若延迟异常, 先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性, 再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk, 内容仍保持可读。

实践清单: 检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms, 并与 batchSize=1 基线对比。相关关键词: 会话 Session 与 Message 持久化、RAG、Embedding、LanceDB、切块、召回、TopK。

66. PostgreSQL（知识库 CRUD 与回收站）

Document 存在 Postgres, 经 Prisma 管理。软删除用 deletedAt; 恢复后需重新 indexDocumentChunks 写回向量。文件名 filename 与 chunk 元数据对齐。在「知识库 CRUD 与回收站」场景下, 建议把输入规模、硬件与实测延迟记进实验笔记。第 66 段强调: 召回片段应可追溯到文件名与页码, 回答中给出依据。若延迟异常, 先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性, 再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk, 内容仍保持可读。

实践清单: 检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms, 并与 batchSize=1 基线对比。相关关键词: 知识库 CRUD 与回收站、RAG、Embedding、LanceDB、切块、召回、TopK。

67. PDF 入库（检索页冷热对比实验）

pdf-parse 抽文本与分页，清洗页脚与软换行后 createDocument。若传 pages，则按页切块并写入真实 page；否则全文切块 page=0。在「检索页冷热对比实验」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 67 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：检索页冷热对比实验、RAG、Embedding、LanceDB、切块、召回、TopK。

68. 检索 API（bench-retrieval 固定参数）

POST /api/retrieval 接收 query、k、可选 docId。searchSnippets 返回 hits 与 timings：openTableMs、searchMs、mapMs，路由再补 validateMs 与 totalMs。在「bench-retrieval 固定参数」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 68 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：bench-retrieval 固定参数、RAG、Embedding、LanceDB、切块、召回、TopK。

69. 耗时解读（HF 镜像与模型缓存）

冷启动首请求常含模型加载；热路径看 searchMs。入库优化看 embedMs 与 POST /api/documents 墙钟，不要用检索耗时衡量批量 embed。在「HF 镜像与模型缓存」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 69 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：HF 镜像与模型缓存、RAG、Embedding、LanceDB、切块、召回、TopK。

70. 质量回归（Windows 上 ONNX 注意事项）

对照 batchSize=1 与 16 的向量余弦应接近 1；同 query 的 top-k 文档 id 排序应大致稳定。切块切断关键句时召回会抖，需检查分隔符与 overlap。在「Windows 上 ONNX 注意

事项」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 70 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：Windows 上 ONNX 注意事项、RAG、Embedding、LanceDB、切块、召回、TopK。

71. RAG 总览（Chunk 元数据 filename 与 page）

检索增强生成把知识库与大语言模型解耦。系统先检索相关片段，再把片段作为上下文交给模型生成回答，便于更新知识、追溯出处，也降低幻觉。在「Chunk 元数据 filename 与 page」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 71 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：Chunk 元数据 filename 与 page、RAG、Embedding、LanceDB、切块、召回、TopK。

72. 切块策略（软删除后向量清理）

RecursiveCharacterTextSplitter 从粗到细尝试分隔符：空行、换行、中英文句读、逗号、空格，最后才按字符硬切。默认 maxChars=500、overlap=100，兼顾召回粒度与上下文连贯。在「软删除后向量清理」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 72 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：软删除后向量清理、RAG、Embedding、LanceDB、切块、召回、TopK。

73. Embedding（恢复文档后重建索引）

本项目使用 Xenova/all-MiniLM-L6-v2 量化 ONNX 模型，在 Node 本地推理，输出 384 维 L2 归一化向量。写入 LanceDB 时由 Embedding Function 自动生成 vector。在「恢复文档后重建索引」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 73 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：恢复文档后重建索引、RAG、Embedding、LanceDB、切块、召回、TopK。

74. 批量推理（TopK 与相似度阈值）

computeSourceEmbeddings 按 batchSize 切片，一次前向处理多句。n 很小时批量未必更快；n 较大（数十到上百 chunk）时减少前向次数更有收益。注意 padding 与 CPU 小 batch 开销。在「TopK 与相似度阈值」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 74 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：TopK 与相似度阈值、RAG、Embedding、LanceDB、切块、召回、TopK。

75. LanceDB（中文分隔符与英文句号冲突）

向量行包含 id、documentId、title、filename、page、snippet、index 与 vector。表带 embedding_functions 元数据，search(文本) 会自动 embed query。在「中文分隔符与英文句号冲突」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 75 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：中文分隔符与英文句号冲突、RAG、Embedding、LanceDB、切块、召回、TopK。

76. PostgreSQL（overlap 过大导致冗余）

Document 存在 Postgres，经 Prisma 管理。软删除用 deletedAt；恢复后需重新 indexDocumentChunks 写回向量。文件名 filename 与 chunk 元数据对齐。在「overlap 过大导致冗余」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 76 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：overlap 过大导致冗余、RAG、Embedding、LanceDB、切块、召回、TopK。

77. PDF 入库 (maxChars 过小导致碎片)

pdf-parse 抽文本与分页, 清洗页脚与软换行后 createDocument。若传 pages, 则按页切块并写入真实 page; 否则全文切块 page=0。在「maxChars 过小导致碎片」场景下, 建议把输入规模、硬件与实测延迟记进实验笔记。第 77 段强调: 召回片段应可追溯到文件名与页码, 回答中给出依据。若延迟异常, 先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性, 再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk, 内容仍保持可读。

实践清单: 检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms, 并与 batchSize=1 基线对比。相关关键词: maxChars 过小导致碎片、RAG、Embedding、LanceDB、切块、召回、TopK。

78. 检索 API (批量大小 8/16/32 扫参)

POST /api/retrieval 接收 query、k、可选 docId。searchSnippets 返回 hits 与 timings: openTableMs、searchMs、mapMs, 路由再补 validateMs 与 totalMs。在「批量大小 8/16/32 扫参」场景下, 建议把输入规模、硬件与实测延迟记进实验笔记。第 78 段强调: 召回片段应可追溯到文件名与页码, 回答中给出依据。若延迟异常, 先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性, 再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk, 内容仍保持可读。

实践清单: 检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms, 并与 batchSize=1 基线对比。相关关键词: 批量大小 8/16/32 扫参、RAG、Embedding、LanceDB、切块、召回、TopK。

79. 耗时解读 (padding 最长句成本)

冷启动首请求常含模型加载; 热路径看 searchMs。入库优化看 embedMs 与 POST /api/documents 墙钟, 不要用检索耗时衡量批量 embed。在「padding 最长句成本」场景下, 建议把输入规模、硬件与实测延迟记进实验笔记。第 79 段强调: 召回片段应可追溯到文件名与页码, 回答中给出依据。若延迟异常, 先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性, 再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk, 内容仍保持可读。

实践清单: 检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms, 并与 batchSize=1 基线对比。相关关键词: padding 最长句成本、RAG、Embedding、LanceDB、切块、召回、TopK。

80. 质量回归 (warmup 后再测平均值)

对照 batchSize=1 与 16 的向量余弦应接近 1; 同 query 的 top-k 文档 id 排序应大致稳定。切块切断关键句时召回会抖, 需检查分隔符与 overlap。在「warmup 后再测平均值」场景下, 建议把输入规模、硬件与实测延迟记进实验笔记。第 80 段强调: 召回片段应可追

溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：warmup 后再测平均值、RAG、Embedding、LanceDB、切块、召回、TopK。

81. RAG 总览（员工手册与请假出差报销）

检索增强生成把知识库与大语言模型解耦。系统先检索相关片段，再把片段作为上下文交给模型生成回答，便于更新知识、追溯出处，也降低幻觉。在「员工手册与请假出差报销」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 81 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：员工手册与请假出差报销、RAG、Embedding、LanceDB、切块、召回、TopK。

82. 切块策略（开发规范 React TypeScript Next.js）

RecursiveCharacterTextSplitter 从粗到细尝试分隔符：空行、换行、中英文句读、逗号、空格，最后才按字符硬切。默认 maxChars=500、overlap=100，兼顾召回粒度与上下文连贯。在「开发规范 React TypeScript Next.js」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 82 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：开发规范 React TypeScript Next.js、RAG、Embedding、LanceDB、切块、召回、TopK。

83. Embedding（Prisma 与 PostgreSQL 建模）

本项目使用 Xenova/all-MiniLM-L6-v2 量化 ONNX 模型，在 Node 本地推理，输出 384 维 L2 归一化向量。写入 LanceDB 时由 Embedding Function 自动生成 vector。在「Prisma 与 PostgreSQL 建模」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 83 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的

n/batches/ms, 并与 batchSize=1 基线对比。相关关键词: Prisma 与 PostgreSQL 建模、RAG、Embedding、LanceDB、切块、召回、TopK。

84. 批量推理（鉴权 Token 与 apiFetch）

computeSourceEmbeddings 按 batchSize 切片, 一次前向处理多句。n 很小时批量未必更快; n 较大(数十到上百 chunk)时减少前向次数更有收益。注意 padding 与 CPU 小 batch 开销。在「鉴权 Token 与 apiFetch」场景下, 建议把输入规模、硬件与实测延迟记进实验笔记。第 84 段强调: 召回片段应可追溯到文件名与页码, 回答中给出依据。若延迟异常, 先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性, 再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk, 内容仍保持可读。

实践清单: 检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms, 并与 batchSize=1 基线对比。相关关键词: 鉴权 Token 与 apiFetch、RAG、Embedding、LanceDB、切块、召回、TopK。

85. LanceDB（会话 Session 与 Message 持久化）

向量行包含 id、documentId、title、filename、page、snippet、index 与 vector。表带 embedding_functions 元数据, search(文本) 会自动 embed query。在「会话 Session 与 Message 持久化」场景下, 建议把输入规模、硬件与实测延迟记进实验笔记。第 85 段强调: 召回片段应可追溯到文件名与页码, 回答中给出依据。若延迟异常, 先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性, 再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk, 内容仍保持可读。

实践清单: 检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms, 并与 batchSize=1 基线对比。相关关键词: 会话 Session 与 Message 持久化、RAG、Embedding、LanceDB、切块、召回、TopK。

86. PostgreSQL（知识库 CRUD 与回收站）

Document 存在 Postgres, 经 Prisma 管理。软删除用 deletedAt; 恢复后需重新 indexDocumentChunks 写回向量。文件名 filename 与 chunk 元数据对齐。在「知识库 CRUD 与回收站」场景下, 建议把输入规模、硬件与实测延迟记进实验笔记。第 86 段强调: 召回片段应可追溯到文件名与页码, 回答中给出依据。若延迟异常, 先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性, 再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk, 内容仍保持可读。

实践清单: 检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms, 并与 batchSize=1 基线对比。相关关键词: 知识库 CRUD 与回收站、RAG、Embedding、LanceDB、切块、召回、TopK。

87. PDF 入库（检索页冷热对比实验）

pdf-parse 抽文本与分页，清洗页脚与软换行后 createDocument。若传 pages，则按页切块并写入真实 page；否则全文切块 page=0。在「检索页冷热对比实验」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 87 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：检索页冷热对比实验、RAG、Embedding、LanceDB、切块、召回、TopK。

88. 检索 API（bench-retrieval 固定参数）

POST /api/retrieval 接收 query、k、可选 docId。searchSnippets 返回 hits 与 timings：openTableMs、searchMs、mapMs，路由再补 validateMs 与 totalMs。在「bench-retrieval 固定参数」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 88 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：bench-retrieval 固定参数、RAG、Embedding、LanceDB、切块、召回、TopK。

89. 耗时解读（HF 镜像与模型缓存）

冷启动首请求常含模型加载；热路径看 searchMs。入库优化看 embedMs 与 POST /api/documents 墙钟，不要用检索耗时衡量批量 embed。在「HF 镜像与模型缓存」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 89 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：HF 镜像与模型缓存、RAG、Embedding、LanceDB、切块、召回、TopK。

90. 质量回归（Windows 上 ONNX 注意事项）

对照 batchSize=1 与 16 的向量余弦应接近 1；同 query 的 top-k 文档 id 排序应大致稳定。切块切断关键句时召回会抖，需检查分隔符与 overlap。在「Windows 上 ONNX 注意

事项」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 90 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：Windows 上 ONNX 注意事项、RAG、Embedding、LanceDB、切块、召回、TopK。

91. RAG 总览（Chunk 元数据 filename 与 page）

检索增强生成把知识库与大语言模型解耦。系统先检索相关片段，再把片段作为上下文交给模型生成回答，便于更新知识、追溯出处，也降低幻觉。在「Chunk 元数据 filename 与 page」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 91 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：Chunk 元数据 filename 与 page、RAG、Embedding、LanceDB、切块、召回、TopK。

92. 切块策略（软删除后向量清理）

RecursiveCharacterTextSplitter 从粗到细尝试分隔符：空行、换行、中英文句读、逗号、空格，最后才按字符硬切。默认 maxChars=500、overlap=100，兼顾召回粒度与上下文连贯。在「软删除后向量清理」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 92 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：软删除后向量清理、RAG、Embedding、LanceDB、切块、召回、TopK。

93. Embedding（恢复文档后重建索引）

本项目使用 Xenova/all-MiniLM-L6-v2 量化 ONNX 模型，在 Node 本地推理，输出 384 维 L2 归一化向量。写入 LanceDB 时由 Embedding Function 自动生成 vector。在「恢复文档后重建索引」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 93 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：恢复文档后重建索引、RAG、Embedding、LanceDB、切块、召回、TopK。

94. 批量推理（TopK 与相似度阈值）

computeSourceEmbeddings 按 batchSize 切片，一次前向处理多句。n 很小时批量未必更快；n 较大（数十到上百 chunk）时减少前向次数更有收益。注意 padding 与 CPU 小 batch 开销。在「TopK 与相似度阈值」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 94 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：TopK 与相似度阈值、RAG、Embedding、LanceDB、切块、召回、TopK。

95. LanceDB（中文分隔符与英文句号冲突）

向量行包含 id、documentId、title、filename、page、snippet、index 与 vector。表带 embedding_functions 元数据，search(文本) 会自动 embed query。在「中文分隔符与英文句号冲突」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 95 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：中文分隔符与英文句号冲突、RAG、Embedding、LanceDB、切块、召回、TopK。

96. PostgreSQL（overlap 过大导致冗余）

Document 存在 Postgres，经 Prisma 管理。软删除用 deletedAt；恢复后需重新 indexDocumentChunks 写回向量。文件名 filename 与 chunk 元数据对齐。在「overlap 过大导致冗余」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 96 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：overlap 过大导致冗余、RAG、Embedding、LanceDB、切块、召回、TopK。

97. PDF 入库 (maxChars 过小导致碎片)

pdf-parse 抽文本与分页, 清洗页脚与软换行后 createDocument。若传 pages, 则按页切块并写入真实 page; 否则全文切块 page=0。在「maxChars 过小导致碎片」场景下, 建议把输入规模、硬件与实测延迟记进实验笔记。第 97 段强调: 召回片段应可追溯到文件名与页码, 回答中给出依据。若延迟异常, 先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性, 再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk, 内容仍保持可读。

实践清单: 检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms, 并与 batchSize=1 基线对比。相关关键词: maxChars 过小导致碎片、RAG、Embedding、LanceDB、切块、召回、TopK。

98. 检索 API (批量大小 8/16/32 扫参)

POST /api/retrieval 接收 query、k、可选 docId。searchSnippets 返回 hits 与 timings: openTableMs、searchMs、mapMs, 路由再补 validateMs 与 totalMs。在「批量大小 8/16/32 扫参」场景下, 建议把输入规模、硬件与实测延迟记进实验笔记。第 98 段强调: 召回片段应可追溯到文件名与页码, 回答中给出依据。若延迟异常, 先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性, 再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk, 内容仍保持可读。

实践清单: 检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms, 并与 batchSize=1 基线对比。相关关键词: 批量大小 8/16/32 扫参、RAG、Embedding、LanceDB、切块、召回、TopK。

99. 耗时解读 (padding 最长句成本)

冷启动首请求常含模型加载; 热路径看 searchMs。入库优化看 embedMs 与 POST /api/documents 墙钟, 不要用检索耗时衡量批量 embed。在「padding 最长句成本」场景下, 建议把输入规模、硬件与实测延迟记进实验笔记。第 99 段强调: 召回片段应可追溯到文件名与页码, 回答中给出依据。若延迟异常, 先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性, 再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk, 内容仍保持可读。

实践清单: 检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms, 并与 batchSize=1 基线对比。相关关键词: padding 最长句成本、RAG、Embedding、LanceDB、切块、召回、TopK。

100. 质量回归 (warmup 后再测平均值)

对照 batchSize=1 与 16 的向量余弦应接近 1; 同 query 的 top-k 文档 id 排序应大致稳定。切块切断关键句时召回会抖, 需检查分隔符与 overlap。在「warmup 后再测平均值」场景下, 建议把输入规模、硬件与实测延迟记进实验笔记。第 100 段强调: 召回片段应可

追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：warmup 后再测平均值、RAG、Embedding、LanceDB、切块、召回、TopK。

101. RAG 总览（员工手册与请假出差报销）

检索增强生成把知识库与大语言模型解耦。系统先检索相关片段，再把片段作为上下文交给模型生成回答，便于更新知识、追溯出处，也降低幻觉。在「员工手册与请假出差报销」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 101 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：员工手册与请假出差报销、RAG、Embedding、LanceDB、切块、召回、TopK。

102. 切块策略（开发规范 React TypeScript Next.js）

RecursiveCharacterTextSplitter 从粗到细尝试分隔符：空行、换行、中英文句读、逗号、空格，最后才按字符硬切。默认 maxChars=500、overlap=100，兼顾召回粒度与上下文连贯。在「开发规范 React TypeScript Next.js」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 102 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：开发规范 React TypeScript Next.js、RAG、Embedding、LanceDB、切块、召回、TopK。

103. Embedding（Prisma 与 PostgreSQL 建模）

本项目使用 Xenova/all-MiniLM-L6-v2 量化 ONNX 模型，在 Node 本地推理，输出 384 维 L2 归一化向量。写入 LanceDB 时由 Embedding Function 自动生成 vector。在「Prisma 与 PostgreSQL 建模」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 103 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的

n/batches/ms, 并与 batchSize=1 基线对比。相关关键词: Prisma 与 PostgreSQL 建模、RAG、Embedding、LanceDB、切块、召回、TopK。

104. 批量推理 (鉴权 Token 与 apiFetch)

computeSourceEmbeddings 按 batchSize 切片, 一次前向处理多句。n 很小时批量未必更快; n 较大 (数十到上百 chunk) 时减少前向次数更有收益。注意 padding 与 CPU 小 batch 开销。在「鉴权 Token 与 apiFetch」场景下, 建议把输入规模、硬件与实测延迟记进实验笔记。第 104 段强调: 召回片段应可追溯到文件名与页码, 回答中给出依据。若延迟异常, 先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性, 再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk, 内容仍保持可读。

实践清单: 检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms, 并与 batchSize=1 基线对比。相关关键词: 鉴权 Token 与 apiFetch、RAG、Embedding、LanceDB、切块、召回、TopK。

105. LanceDB (会话 Session 与 Message 持久化)

向量行包含 id、documentId、title、filename、page、snippet、index 与 vector。表带 embedding_functions 元数据, search(文本) 会自动 embed query。在「会话 Session 与 Message 持久化」场景下, 建议把输入规模、硬件与实测延迟记进实验笔记。第 105 段强调: 召回片段应可追溯到文件名与页码, 回答中给出依据。若延迟异常, 先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性, 再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk, 内容仍保持可读。

实践清单: 检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms, 并与 batchSize=1 基线对比。相关关键词: 会话 Session 与 Message 持久化、RAG、Embedding、LanceDB、切块、召回、TopK。

106. PostgreSQL (知识库 CRUD 与回收站)

Document 存在 Postgres, 经 Prisma 管理。软删除用 deletedAt; 恢复后需重新 indexDocumentChunks 写回向量。文件名 filename 与 chunk 元数据对齐。在「知识库 CRUD 与回收站」场景下, 建议把输入规模、硬件与实测延迟记进实验笔记。第 106 段强调: 召回片段应可追溯到文件名与页码, 回答中给出依据。若延迟异常, 先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性, 再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk, 内容仍保持可读。

实践清单: 检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms, 并与 batchSize=1 基线对比。相关关键词: 知识库 CRUD 与回收站、RAG、Embedding、LanceDB、切块、召回、TopK。

107. PDF 入库（检索页冷热对比实验）

pdf-parse 抽文本与分页，清洗页脚与软换行后 createDocument。若传 pages，则按页切块并写入真实 page；否则全文切块 page=0。在「检索页冷热对比实验」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 107 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：检索页冷热对比实验、RAG、Embedding、LanceDB、切块、召回、TopK。

108. 检索 API（bench-retrieval 固定参数）

POST /api/retrieval 接收 query、k、可选 docId。searchSnippets 返回 hits 与 timings：openTableMs、searchMs、mapMs，路由再补 validateMs 与 totalMs。在「bench-retrieval 固定参数」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 108 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：bench-retrieval 固定参数、RAG、Embedding、LanceDB、切块、召回、TopK。

109. 耗时解读（HF 镜像与模型缓存）

冷启动首请求常含模型加载；热路径看 searchMs。入库优化看 embedMs 与 POST /api/documents 墙钟，不要用检索耗时衡量批量 embed。在「HF 镜像与模型缓存」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 109 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：HF 镜像与模型缓存、RAG、Embedding、LanceDB、切块、召回、TopK。

110. 质量回归（Windows 上 ONNX 注意事项）

对照 batchSize=1 与 16 的向量余弦应接近 1；同 query 的 top-k 文档 id 排序应大致稳定。切块切断关键句时召回会抖，需检查分隔符与 overlap。在「Windows 上 ONNX 注意

事项」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 110 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：Windows 上 ONNX 注意事项、RAG、Embedding、LanceDB、切块、召回、TopK。

111. RAG 总览（Chunk 元数据 filename 与 page）

检索增强生成把知识库与大语言模型解耦。系统先检索相关片段，再把片段作为上下文交给模型生成回答，便于更新知识、追溯出处，也降低幻觉。在「Chunk 元数据 filename 与 page」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 111 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：Chunk 元数据 filename 与 page、RAG、Embedding、LanceDB、切块、召回、TopK。

112. 切块策略（软删除后向量清理）

RecursiveCharacterTextSplitter 从粗到细尝试分隔符：空行、换行、中英文句读、逗号、空格，最后才按字符硬切。默认 maxChars=500、overlap=100，兼顾召回粒度与上下文连贯。在「软删除后向量清理」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 112 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：软删除后向量清理、RAG、Embedding、LanceDB、切块、召回、TopK。

113. Embedding（恢复文档后重建索引）

本项目使用 Xenova/all-MiniLM-L6-v2 量化 ONNX 模型，在 Node 本地推理，输出 384 维 L2 归一化向量。写入 LanceDB 时由 Embedding Function 自动生成 vector。在「恢复文档后重建索引」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 113 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持

可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：恢复文档后重建索引、RAG、Embedding、LanceDB、切块、召回、TopK。

114. 批量推理（TopK 与相似度阈值）

computeSourceEmbeddings 按 batchSize 切片，一次前向处理多句。n 很小时批量未必更快；n 较大（数十到上百 chunk）时减少前向次数更有收益。注意 padding 与 CPU 小 batch 开销。在「TopK 与相似度阈值」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 114 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：TopK 与相似度阈值、RAG、Embedding、LanceDB、切块、召回、TopK。

115. LanceDB（中文分隔符与英文句号冲突）

向量行包含 id、documentId、title、filename、page、snippet、index 与 vector。表带 embedding_functions 元数据，search(文本) 会自动 embed query。在「中文分隔符与英文句号冲突」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 115 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：中文分隔符与英文句号冲突、RAG、Embedding、LanceDB、切块、召回、TopK。

116. PostgreSQL（overlap 过大导致冗余）

Document 存在 Postgres，经 Prisma 管理。软删除用 deletedAt；恢复后需重新 indexDocumentChunks 写回向量。文件名 filename 与 chunk 元数据对齐。在「overlap 过大导致冗余」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 116 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：overlap 过大导致冗余、RAG、

Embedding、LanceDB、切块、召回、TopK。

117. PDF 入库（maxChars 过小导致碎片）

pdf-parse 抽文本与分页，清洗页脚与软换行后 createDocument。若传 pages，则按页切块并写入真实 page；否则全文切块 page=0。在「maxChars 过小导致碎片」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 117 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：maxChars 过小导致碎片、RAG、Embedding、LanceDB、切块、召回、TopK。

118. 检索 API（批量大小 8/16/32 扫参）

POST /api/retrieval 接收 query、k、可选 docId。searchSnippets 返回 hits 与 timings：openTableMs、searchMs、mapMs，路由再补 validateMs 与 totalMs。在「批量大小 8/16/32 扫参」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 118 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：批量大小 8/16/32 扫参、RAG、Embedding、LanceDB、切块、召回、TopK。

119. 耗时解读（padding 最长句成本）

冷启动首请求常含模型加载；热路径看 searchMs。入库优化看 embedMs 与 POST /api/documents 墙钟，不要用检索耗时衡量批量 embed。在「padding 最长句成本」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 119 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、embedding 与 ANN 检索四段耗时。工程上优先保证正确性与可观测性，再谈 batchSize 与并发。本段用于拉长文本以便 RecursiveCharacterTextSplitter 产生更多 chunk，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 schema、观察 [embed:write] 日志中的 n/batches/ms，并与 batchSize=1 基线对比。相关关键词：padding 最长句成本、RAG、Embedding、LanceDB、切块、召回、TopK。

120. 质量回归（warmup 后再测平均值）

对照 batchSize=1 与 16 的向量余弦应接近 1；同 query 的 top-k 文档 id 排序应大致稳

定。切块切断关键句时召回会抖，需检查分隔符与 `overlap`。在「warmup 后再测平均值」场景下，建议把输入规模、硬件与实测延迟记进实验笔记。第 120 段强调：召回片段应可追溯到文件名与页码，回答中给出依据。若延迟异常，先区分冷加载、表打开、`embedding` 与 `ANN` 检索四段耗时。工程上优先保证正确性与可观测性，再谈 `batchSize` 与并发。本段用于拉长文本以便 `RecursiveCharacterTextSplitter` 产生更多 `chunk`，内容仍保持可读。

实践清单：检查环境变量、确认 LanceDB 表 `schema`、观察 `[embed:write]` 日志中的 `n/batches/ms`，并与 `batchSize=1` 基线对比。相关关键词：warmup 后再测平均值、RAG、Embedding、LanceDB、切块、召回、TopK。

附录：验收清单

1. 日志出现 `[embed:write]` 且 `n` 明显大于 4。
2. `batchSize=16` 时 `batches ≈ ceil(n/16)`。
3. 先 warmup，再对 `batchSize=1/8/16/32` 各测多轮取平均。
4. 检索同 query，确认 top-k 语义不漂。